

Analyse Statistique du Dataset Kepler Exoplanet Search Results

Akram Halimi - Bilal Jaiel - Kalaivaasan Balakumar
Haron Mataoui - Lucas Ribeiro - Houdaïfa Hsaïni

<https://www.kaggle.com/datasets/nasa/kepler-exoplanet-search-results/data>

Novembre 2025

L'exploration des exoplanètes, passée de la théorie à la réalité scientifique, représente aujourd'hui l'un des domaines les plus dynamiques de l'astrophysique. Le télescope spatial Kepler a joué un rôle central dans cette révolution en utilisant la méthode des transits pour mesurer les variations de luminosité stellaire. Avec plus de 2 662 planètes confirmées à la fin de sa mission (et de sa phase étendue K2), Kepler a fourni des données fondamentales qui continuent d'enrichir notre compréhension des quelques 7 000 exoplanètes recensées à ce jour. Toutefois, la distinction entre véritables planètes et faux positifs demeure un défi analytique majeur.

Problématique : Comment l'analyse multidimensionnelle des propriétés physiques et orbitales permet-elle de caractériser la nature des objets détectés (confirmés, candidats ou faux positifs) et d'identifier les structures latentes des systèmes planétaires ?

Cette étude exploite les variables du catalogue Kepler (rayon, période, profondeur de transit, température, SNR, propriétés stellaires) à travers une approche statistique avancée. Pour la suite, nous utiliserons notamment l'Analyse Canonique des Corrélations (CCA) pour lier les planètes à leurs étoiles hôtes, ainsi que l'Analyse en Composantes Principales (PCA) et le clustering pour réduire la dimensionnalité et segmenter les objets (planètes rocheuses/gazeuses, zone habitable).

Objectif général : L'objectif principal est d'analyser l'influence des paramètres de transit et stellaires sur la classification des objets, afin de discriminer efficacement les exoplanètes des erreurs de détection et de mettre en évidence les corrélations régissant leur formation et leur habitabilité.

1 Introduction

Le télescope spatial Kepler (2009–2018) a observé 150 000 étoiles pour détecter des exoplanètes par la méthode des transits. Cette méthode mesure les baisses de luminosité quand une planète passe devant son étoile. Le dataset contient 9 564 signaux détectés automatiquement (Kepler Objects of Interest ou KOI).

La variable `koi_disposition` classe les objets en **CONFIRMED** (24%, 2 294) pour les vraies planètes confirmées, **CANDIDATE** (23.5%, 2 248) en attente de confirmation, et **FALSE POSITIVE** (52.5%, 5 022) pour les fausses détections. Ce déséquilibre montre la difficulté : les étoiles doubles, les variations stellaires et les erreurs de mesure peuvent ressembler à des transits de planètes.




FIGURE 1 – Répartition montrant le déséquilibre marqué (52.5% faux positifs).

2 Présentation du Dataset

Le dataset contient 50 variables organisées en catégories (Tableau 1). Les **métadonnées** identifient chaque objet avec un numéro unique et un nom officiel pour les planètes confirmées. Les **paramètres orbitaux** mesurent la période, la durée du transit, la profondeur (baisse de luminosité en ppm), et la position du passage (centre ou bord de l'étoile). Les **propriétés planétaires** donnent le rayon de la planète, sa température et le flux reçu. Les **propriétés stellaires** décrivent l'étoile hôte : température, taille, gravité. Les **flags** sont 4 indicateurs binaires signalant des problèmes : forme du signal anormale, profondeur trop grande, décalage de position, ou correspondance avec une étoile double connue. Enfin `koi_score` est une probabilité entre 0 et 1 indiquant la confiance que c'est une vraie planète.

La qualité du dataset est bonne : 8.48% de valeurs manquantes en moyenne (médiane 6%). Les identifiants et coordonnées sont complets à 100%. Les variables d'incertitude ont 4–6% de NaN. La variable `kepler_name` a 76% de NaN car seules les planètes confirmées reçoivent un nom officiel. 87.4% des données viennent de DR25, la dernière version officielle de Kepler.

TABLE 1 – Liste complète des 50 variables du dataset Kepler

Catégorie	Variable	Description
Identifiants	rowid	Numéro de ligne
	kepid	Identifiant Kepler
	kepoi_name kepler_name	Nom KOI Nom officiel (76% NaN)
Orbitaux	koi_period	Période orbitale (jours)
	koi_time0bk	Temps premier transit
	koi_impact	Paramètre impact (0–1)
	koi_duration	Durée transit (heures)
	koi_depth_err1	Profondeur transit (ppm) Incertitudes profondeur
Planétaires	koi_prad	Rayon planète ($R_{\oplus}$)
	koi_teq	Température équilibre (K)
	koi_insol	Insolation ($F_{\oplus}$)
	koi_insol_err1	Incertitudes insolation
Stellaires	koi_steff	Température étoile (K)
	koi_slogg	Gravité surface log (cgs)
	koi_srad	Rayon étoile ($R_{\odot}$)
Flags	koi_fpflag_nt	Forme non-transit
	koi_fpflag_ss	Éclipse stellaire
	koi_fpflag_co	Décalage centroïde
	koi_fpflag_ec	Étoile double connue
Validation	koi_disposition	Classe finale (target)

3 Méthodologie

Nous avons supprimé les variables inutiles et celles entièrement vides (`koi_teq_err1/err2` : 100% manquantes). Le dataset a 8.48% de valeurs manquantes en moyenne (médiane 6%), avec 87.4% des données de la version DR25. Les tests utilisés sont : Shapiro-Wilk (test de normalité), Kruskal-Wallis (comparaison entre classes), corrélations de Spearman (relations entre variables), et χ^2 (lien entre flags et classes).

4 Résultats

4.1 Distributions des variables orbitales

Les paramètres orbitaux montrent des asymétries très fortes (Tableau 2). La période orbitale a une moyenne de 75.2 jours mais une médiane de seulement 9.3 jours, avec un coefficient d’asymétrie de 96.5 et un kurtosis dépassant 9300. Cette distribution écrasée vers les courtes périodes vient d’un biais de détection : la probabilité qu’une planète passe devant son étoile vue depuis la Terre est $P \approx R_*/a$, où R_* est le rayon de l’étoile et a la distance de la planète. Pour une planète proche, cette probabilité est grande. De plus, la loi de Kepler $P^2 \propto a^3$ montre que les planètes proches ont des périodes courtes et transitent donc plusieurs fois pendant la mission, multipliant les chances de détection. À l’inverse, une planète comme Jupiter (période 11.86 ans) ne transite qu’une ou deux fois sur les quatre années d’observation, rendant sa confirmation difficile.

TABLE 2 – Statistiques des variables orbitales clés

Variable	μ	M	Skew/Kurt
koi_period (j)	75.2	9.3	96.5 / 9386
koi_prad ($R_{\oplus}$)	102.9	2.7	29.7 / Extr.
koi_insol ($F_{\oplus}$)	774.5	23.1	51.2 / Élevé
koi_depth (ppm)	2379.1	435	Asymétrique

La médiane de R_p ($2.7 R_{\oplus}$) révèle une classe de super-Terres absente de notre système solaire, tandis que les

outliers ($> 200k R_{\oplus}$) signalent des binaires non filtrées. L’insolation médiane ($23.1 F_{\oplus}$) confirme le biais de détection vers les orbites courtes et les températures extrêmes ($> 2000 K$). Les profondeurs atteignent 1.5M ppm, loin des 10k ppm typiques d’un Jupiter. Enfin, le test de Shapiro-Wilk rejette la normalité pour toutes les variables ($p < 0.05$), conséquence attendue des relations non-linéaires de Kepler.




FIGURE 2 – Estimations de densité par noyau montrant la séparation nette entre classes. Les planètes confirmées (vert) forment des pics sur courtes périodes et petits rayons, tandis que les faux positifs (rouge) s’étendent vers des valeurs extrêmes physiquement aberrantes.

4.2 Propriétés stellaires

Les étoiles hôtes sont très homogènes : température médiane de 5778 K (comme le Soleil), gravité de 4.4 cgs et rayon de $0.98 R_{\odot}$, confirmant que Kepler a ciblé des étoiles similaires au Soleil. Ce choix vient de raisons physiques : les étoiles de type G comme le Soleil vivent environ 10 milliards d’années, assez longtemps pour que la vie puisse évoluer, et leur zone habitable est à une distance facilitant la détection.

Les valeurs extrêmes ($T > 8000 K$, $R > 200 R_{\odot}$) correspondent aux géantes rouges dont la taille immense et la variabilité compliquent la détection. L’absence de naines blanches ou d’objets compacts confirme le ciblage exclusif d’étoiles actives normales.

4.3 Corrélations physiques causales

L’analyse de Spearman révèle des corrélations fortes qui reflètent des lois physiques (Figure 3). La corrélation entre `koi_teq` et `koi_insol` traduit la relation thermodynamique $T \propto \text{Flux}^{1/4}$, où la température d’une planète varie comme la racine quatrième du flux reçu. La corrélation négative entre `koi_period` et `koi_insol` combine la loi de Kepler (période liée à la distance) avec la dilution du flux en $1/d^2$. La profondeur du transit cor-

rôle fortement avec le rayon planétaire selon profondeur $\propto (R_p/R_*)^2$. La corrélation inverse entre `koi_srad` et `koi_slogg` reflète la géométrie stellaire où un rayon plus grand implique une gravité de surface plus faible.




FIGURE 3 – Heatmap des corrélations entre variables physiques. Les corrélations fortes (rouge/bleu foncé) ne sont pas fortuites mais reflètent des relations causales dictées par les lois de la physique.

Ces multicollinéarités nécessiteront une PCA en modélisation pour éviter l’instabilité des coefficients.

5 Analyse Différentielle

5.1 Séparations physiques observées

Le test de Kruskal-Wallis confirme des différences significatives ($p < 0.05$) entre classes pour `koi_prad`, `koi_duration`, `koi_impact` et `koi_depth`. Les distributions KDE (Figure 2) montrent que les planètes confirmées forment un groupe dense avec des rayons cohérents ($1\text{--}5 R_{\oplus}$) et des relations période-durée compatibles avec les lois de Kepler, reflétant les contraintes géométriques des transits authentiques.

Les faux positifs occupent les régions aberrantes : rayons $> 20 R_{\oplus}$ (impossibles pour des planètes), paramètres d’impact > 1 (la planète ne passerait pas devant l’étoile), valeurs atteignant 100 invalidant totalement la physique des transits. Ces configurations viennent de la confusion entre plusieurs étoiles qui se superposent dans le détecteur.

Les propriétés stellaires ne diffèrent pas significativement entre classes, confirmation physique que les étoiles hôtes ne portent pas d’information sur l’authenticité de l’objet en transit.

5.2 Variable `koi_score` : prédicteur bimodal

La distribution de `koi_score` est extrêmement polarisée (Figure 4) : CONFIRMED/CANDIDATE à médiane ~ 1.0 , FALSE POSITIVE à ~ 0 , avec $Q_1 = 0$ et $Q_3 = 1$. Cette séparation quasi-parfaite en fait un prédicteur puissant mais soulève un risque de *data leakage*. Les

scores intermédiaires (0.3–0.7) sont rares et représentent les cas ambigus nécessitant observations de suivi.




FIGURE 4 – Histogramme bimodal révélant la polarisation extrême. La seule variable sans valeurs aberrantes, confirmant son statut de probabilité normalisée plutôt que de mesure physique brute.

6 Flags Techniques

Le test du Chi² révèle un lien très fort entre les quatre flags et `koi_disposition` ($p \ll 0.001$). L’activation d’un seul flag prédit FALSE POSITIVE avec $> 95\%$ de probabilité (Figure 5).




FIGURE 5 – Fréquences d’activation. `koi_fflag_ss` (éclipses stellaires) est le plus fréquent (23.2%).

Le flag `koi_fflag_nt` (18.8%) détecte les courbes avec une forme anormale révélant des étoiles doubles. Le flag `koi_fflag_ss` (23.2%) identifie les éclipses stellaires quand la baisse de luminosité dépasse 10%. Le flag `koi_fflag_co` (19.5%) mesure un décalage de position signalant une contamination par une étoile d’arrière-plan. Le flag `koi_fflag_ec` (12.0%) vérifie la correspondance avec des étoiles doubles connues. Ces flags permettent de classer facilement les faux positifs mais ne distinguent pas les candidats des confirmés (tous deux ont flags=0).

7 Valeurs Aberrantes

Les boxplots (Figure 6) révèlent trois catégories d'outliers nécessitant des traitements différenciés.




FIGURE 6 — Écrasement des distributions par valeurs extrêmes. Les outliers de `koi_grad` et `koi_insol` atteignent des valeurs physiquement impossibles, signalant des binaires ou erreurs.

Le nettoyage cible les absurdités physiques : rayons $> 200\,000R_{\oplus}$ et profondeurs $> 1.5M$ ppm (binaires), insolation $> 10^7 F_{\oplus}$ et impact > 1 (violation géométrique). Ces cas diffèrent des extrêmes valides (géantes rouges $R > 200R_{\odot}$, compagnons chauds).

8 Analyse Multivariée

Les pairplots `koi_period` $\times$ `koi_duration` $\times$ `koi_grad` révèlent un cluster dense des CONFIRMED dans le domaine planétaire cohérent et une dispersion périphérique des FALSE POSITIVE vers les régions aberrantes. Le croisement `koi_steff` $\times$ `koi_slogg` reproduit le diagramme de Hertzsprung-Russell (Figure 7) : séquence principale en banane dense où se concentrent les CONFIRMED, et branche géantes où les FALSE POSITIVE sont sur-représentés en raison de la variabilité stellaire intrinsèque et de la taille immense qui dilue le signal de transit de petites planètes.




FIGURE 7 — Température effective vs gravité de surface reproduisant le diagramme HR. La séquence principale concentre les planètes confirmées, les géantes montrent plus de faux positifs.




FIGURE 8 — La visualisation des coordonnées $ra \times dec$ reconstruit la grille CCD de Kepler avec une homogénéité spatiale, confirmant l'absence de biais géographique dans les fausses détections.

9 Conclusion

Cette analyse révèle plusieurs résultats clés. Les 9 564 observations montrent un déséquilibre (52.5% faux positifs, 24% confirmés, 23.5% candidats) et des distributions orbitales très asymétriques (skewness > 96 , kurtosis > 9300) dues aux biais des transits : les planètes proches (médiane 9.3 jours) dominent les détections. Le rayon médian de $2.7 R_{\oplus}$ confirme la prédominance des super-Terres et mini-Neptunes. Les corrélations de Spearman révèlent des relations causales dictées par les lois physiques. L'analyse différentielle montre que l'identification des faux positifs est facile via les flags techniques (précision $> 95\%$), mais distinguer des candidats et les confirmés reste difficile. Le test de Kruskal-Wallis confirme des différences significatives entre classes. Les perspectives incluent la PCA pour visualiser la séparation des classes, la CCA pour les couplages planètes-étoiles, et le clustering pour identifier les sous-populations naturelles.